

# Previsão de Evapotranspiração de Referência com *Deep Learning* e Aprendizado Federado

Fernando dos Santos Alves Fernandes

*Redes Neurais e Aprendizado Profundo (PCC177)*

*Programa de Pós-graduação em Ciência da Computação (PPGCC)*

*Departamento de Computação (DECOM)*

*Universidade Federal de Ouro Preto (UFOP)*

Ouro Preto, Minas Gerais, Brasil

fernando.santos@aluno.ufop.edu.br

**Resumo**—A estimativa precisa da evapotranspiração de referência (ET<sub>0</sub>) é fundamental para o planejamento da irrigação em um contexto de aumento da demanda alimentar e crescente escassez hídrica, intensificada pelas mudanças climáticas. Em regiões com limitação de dados meteorológicos e elevada variabilidade climática, essa tarefa torna-se particularmente desafiadora. Este trabalho avalia o desempenho de arquiteturas de redes neurais profundas na previsão multivariada da ET<sub>0</sub> nos seis climas brasileiros, comparando modelos LSTM, TCN e Transformer, treinados a partir de variáveis meteorológicas como radiação solar, velocidade do vento, temperaturas máxima e mínima, umidade relativa do ar e precipitação. Os resultados indicam que o modelo LSTM apresentou melhor desempenho em quatro dos seis climas analisados, sendo selecionado como modelo local para a etapa de aprendizado federado.

Adicionalmente, foi desenvolvido um *framework* de aprendizado federado síncrono, no qual cada cliente representa um clima distinto, permitindo o treinamento colaborativo e descentralizado com preservação da privacidade dos dados. A agregação dos modelos locais foi realizada por meio do algoritmo *Federated Averaging* (FedAvg), utilizando média ponderada pelo número de amostras de cada cliente. O modelo global federado apresentou desempenho satisfatório em climas com padrões semelhantes, como Tropical Litorâneo, Tropical de Altitude e Tropical Típico, enquanto apresentou desempenho inferior nos climas Equatorial e Semiárido, evidenciando que a similaridade climática entre os clientes influencia a convergência do modelo. Conclui-se que o aprendizado federado é viável para a previsão colaborativa da ET<sub>0</sub>, embora estratégias adaptativas sejam necessárias para lidar com regimes climáticos extremos.

**Palavras-chave:** Evapotranspiração de Referência, Modelos de Previsão Multivariada, Aprendizado Federado.

## I. INTRODUÇÃO

De acordo com a Agência Nacional de Águas e Saneamento Básico (ANA), o Brasil possui mais de 8,2 milhões de hectares de terras agrícolas irrigadas, com potencial para expansão para mais de 13 milhões de hectares até 2040 [1]. A irrigação é o principal consumidor de água doce no mundo, correspondendo a 70% do total disponível, segundo a Organização das Nações Unidas para Alimentação e Agricultura (FAO). No entanto, diante das mudanças climáticas e do aumento previsto na demanda alimentar (cerca de 60% até 2050, para atender às necessidades alimentares de uma população global crescente), a quantidade de água destinada à agricultura não pode exceder 10% de aumento, devido à escassez desse recurso [2].

A evapotranspiração de referência (ET<sub>0</sub>) é uma variável fundamental na estimativa das necessidades hídricas das culturas agrícolas e na formulação de estratégias de manejo racional da irrigação [3]. Sua estimativa precisa é essencial para o planejamento agrícola sustentável, sobretudo em regiões de alta variabilidade climática, como o território brasileiro [4]. Tradicionalmente, a ET<sub>0</sub> é calculada por meio de equações empíricas, como a de Penman-Monteith (FAO-56), que dependem de variáveis meteorológicas obtidas por estações locais [5, 6]. No entanto, a disponibilidade e a qualidade desses dados nem sempre são adequadas, o que limita a confiabilidade das estimativas em determinadas regiões.

Nas últimas décadas, técnicas de aprendizado de máquina (*Machine Learning* – ML) e de aprendizado profundo (*Deep Learning* – DL) têm se destacado como alternativas promissoras para a modelagem de fenômenos ambientais complexos, permitindo capturar relações não lineares entre múltiplas variáveis meteorológicas e a ET<sub>0</sub>. Entre as arquiteturas de redes neurais profundas, destacam-se as redes recorrentes do tipo LSTM (*Long Short-Term Memory*), as redes convolucionais temporais (*Temporal Convolutional Networks* – TCN) e os modelos baseados em transformadores (Transformers), que vêm apresentando desempenho robusto em tarefas de previsão de séries temporais multivariadas [7, 8, 9, 10, 11, 12, 13, 14].

Diante desse cenário, este projeto propõe investigar a aplicação de diferentes arquiteturas de redes neurais profundas na previsão multivariada da evapotranspiração de referência em distintos climas brasileiros. Busca-se compreender quais modelos oferecem melhor desempenho em diferentes regimes climáticos e identificar os fatores meteorológicos que mais influenciam a estimativa da ET<sub>0</sub>.

Adicionalmente, prevê-se o desenvolvimento futuro de uma estrutura distribuída de treinamento, baseada em aprendizado federado (*Federated Learning* – FL), de modo a viabilizar o uso colaborativo de dados meteorológicos sem necessidade de centralização, preservando a privacidade e a heterogeneidade das fontes de dados.

O estudo parte das seguintes hipóteses: (a) modelos de DL multivariados podem superar abordagens tradicionais na previsão de ET<sub>0</sub>; (b) a escolha da arquitetura (LSTM, TCN ou Transformer) influencia significativamente o desempenho

conforme o regime climático; e (c) a adoção de estratégias federadas pode aumentar a escalabilidade e a aplicabilidade prática desses modelos no planejamento de irrigação e gestão hídrica.

O problema de pesquisa pode ser formulado pela pergunta: “*Como desenvolver e avaliar modelos de aprendizado profundo para a estimativa multivariada de evapotranspiração de referência (ETo) em diferentes climas, considerando um cenário de aprendizado federado e distribuído de dados meteorológicos?*”.

## II. REFERENCIAL TEÓRICO

### A. Evapotranspiração de Referência

A evapotranspiração (*ET*) é o processo pelo qual a água da superfície terrestre passa para a atmosfera, do estado líquido para o estado de vapor. Esse processo pode ser definido como “a soma da quantidade de água perdida por uma superfície coberta por vegetação, por meio da evaporação direta da superfície do solo e da água perdida pelas plantas por transpiração” [15]. A necessidade de padronização desse processo para permitir comparações consistentes entre diferentes regiões e climas deu origem à evapotranspiração de referência (*ETo*), que pode ser definida como a taxa de evapotranspiração que ocorre em uma hipotética cultura de referência (normalmente grama ou, em países frios, alfafa), caracterizada como uma área extensa, sem restrição hídrica, com vegetação em crescimento ativo, com altura em torno de 12 cm, albedo (fração de radiação solar refletida) igual a 0,23 e resistência ao transporte de vapor de água constante e igual a  $70 \text{ sm}^{-1}$  (segundos por metro) [5].

O principal método para a estimação da *ETo*, recomendado pela FAO, é o método Penman-Monteith (FAO-56 PM), indicado por sua capacidade de determinar a *ETo* de uma superfície de referência utilizando dados meteorológicos, com valores consistentes em todas as regiões e climas [5]. Entretanto, requer vários parâmetros climatológicos e físicos, alguns medidos diretamente pelas estações meteorológicas, outros derivados de cálculos adicionais. Por esse motivo, uma série de outros métodos empíricos, baseados somente em dados de temperatura do ar ou apenas em dados de radiação solar, além de técnicas mais atuais, como o aprendizado de máquina, podem ser utilizados para a estimativa de *ETo* na ausência de todos os dados meteorológicos.

Os fatores meteorológicos que determinam a evapotranspiração são os parâmetros climáticos associados à energia necessária para a vaporização e remoção do vapor de água da superfície de evaporação, cujos os principais são descritos a seguir.

**Radiação solar:** A evapotranspiração depende da energia disponível para transformar água em vapor, sendo a radiação solar a principal fonte. Essa radiação varia conforme localização geográfica, altitude e época do ano, influenciada pela inclinação da Terra e sua posição em relação ao Sol. Fatores atmosféricos como turbidez e cobertura de nuvens também interferem, refletindo ou absorvendo parte da energia solar [5]. Nem toda a radiação recebida é usada na evaporação:

parte aquece o ar (fluxo de calor sensível), parte aquece a água (fluxo de calor latente) e parte aquece o solo. Assim, fatores atmosféricos e de superfície influenciam o balanço de energia e a quantidade de água evaporada [5].

**Temperatura do ar:** A radiação solar absorvida pela atmosfera e o calor emitido pela Terra aumentam a temperatura do ar. O calor sensível do ar circundante transfere energia para a cultura e influencia a taxa de evapotranspiração. Em dias ensolarados e quentes, a perda de água por evapotranspiração é maior do que em tempo nublado e frio [5].

**Umidade do ar:** A remoção do vapor d’água próximo à planta depende da diferença de pressão de vapor entre a superfície e o ar, que indica o teor de vapor presente na atmosfera. Em regiões áridas, quentes e secas, a baixa umidade relativa e a alta energia aumentam a capacidade da atmosfera de absorver vapor, intensificando a evapotranspiração. Em contraste, em regiões tropicais úmidas, a elevada umidade relativa reduz a demanda por evapotranspiração, pois o ar está próximo da saturação, limitando a absorção adicional de vapor [5].

**Velocidade do vento:** A turbulência gerada pelo vento substitui o ar saturado por ar mais seco, restabelecendo o gradiente de pressão de vapor, principal mecanismo de remoção do vapor d’água. Ventos fortes aceleram a evapotranspiração, enquanto ventos fracos reduzem sua eficiência. Em regiões áridas, com baixa umidade e alta energia, o vento transporta grandes volumes de vapor, elevando a taxa de evapotranspiração. Já em climas úmidos, o efeito do vento é menor, pois a alta umidade limita a absorção de vapor adicional [5].

### B. Domínios climáticos do Brasil

Os climas do Brasil podem ser classificados de acordo com as zonas climáticas ou zonas térmicas e, portanto, podem ser agrupados com base nas características de temperatura e umidade. Neste caso, os tipos climáticos podem ter seis classificações (Figura 1): Equatorial (EQ), Semiárido (SA), Subtropical (ST), Tropical de Altitude (TA), Tropical Litorâneo (TL) e Tropical Típico (TT)) [16, 17].

O clima Equatorial (EQ), predominante na região Norte e em parte do Centro-Oeste, apresenta temperaturas médias acima de  $25^{\circ}\text{C}$  ao longo de todo o ano e elevados índices de precipitação, que podem ultrapassar os 2500 mm anuais. Apesar da constância do calor, ocorrem eventos de friagem durante o inverno, causados por frentes frias provenientes do polo Sul, que podem provocar quedas de temperatura de até  $10^{\circ}\text{C}$ . Mesmo com a frequência de chuvas, há registro de estação seca em áreas como Manaus (AM) [16, 18].

O clima Tropical Típico (TT), também chamado de continental ou semi-úmido, é característico da região central do país, especialmente no Centro-Oeste. É marcado por duas estações bem definidas: um verão quente e chuvoso, e um inverno seco com temperaturas um pouco mais amenas. As temperaturas médias anuais são superiores a  $18^{\circ}\text{C}$ , com amplitude térmica em torno de  $7^{\circ}\text{C}$ . A precipitação varia de 1000 a 1800 mm ao ano, concentrando-se nos meses de verão. No entanto, o Pantanal mato-grossense pode enfrentar longos



Figura 1. Mapa dos climas do Brasil, com seis classificações e principais correntes marítimas. Adaptado de [18].

períodos de estiagem em razão da atuação de massas de ar continentais [16, 18].

O clima Semiárido (SA), típico do Nordeste, apresenta temperaturas médias anuais elevadas (em torno de 27°C), baixa amplitude térmica (cerca de 5°C) e chuvas escassas e irregulares, que não ultrapassam 800 mm por ano. Essa condição de semiaridez resulta da combinação de fatores como a barreira orográfica formada pelo planalto do Borborema, que impede o avanço das massas de ar oceânicas; a presença de uma célula de alta pressão que dissipa o ar úmido; e as águas mais frias do Atlântico Sul-Equatorial, que reduzem a formação de chuvas na região [16, 18].

O clima Tropical de Altitude (TA) ocorre em áreas mais elevadas do Sudeste e em regiões de planaltos e serras. A altitude influencia na moderação das temperaturas, resultando em médias anuais abaixo de 18°C e amplitude térmica entre 7°C e 9°C. O regime de chuvas é semelhante ao do clima tropical, mas há ocorrência de chuvas orográficas (de relevo), e durante o inverno, frentes frias podem provocar geadas, especialmente nas áreas de maior altitude [16, 18].

O clima Tropical Litorâneo (TL), ou tropical úmido, se estende ao longo da costa brasileira, do Rio Grande do Norte ao Rio de Janeiro. A proximidade do oceano contribui para temperaturas médias entre 18°C e 26°C e elevados índices pluviométricos, com médias em torno de 1500 mm anuais, podendo atingir 4000 mm em trechos da serra do Mar no litoral paulista. A sazonalidade das chuvas varia: no Nordeste, as precipitações ocorrem principalmente no outono e inverno, enquanto no Sudeste, concentram-se no verão [16, 18].

O clima Subtropical (ST) predomina na região Sul do Brasil, abaixo do Trópico de Capricórnio, sendo caracterizado por estações do ano bem definidas. Os verões são quentes e os invernos rigorosos, com possibilidade de geadas e até

neve em áreas de maior altitude. As temperaturas no inverno frequentemente ficam abaixo de 0 °C, enquanto a média anual gira em torno de 18°C. As chuvas são bem distribuídas ao longo do ano, com totais anuais superiores a 1250 mm, diferindo dos demais climas brasileiros [16, 18].

### C. Modelos Multivariados

**1) Modelagem de Múltiplas Séries Temporais:** Na previsão univariada, cada série temporal é analisada individualmente, sendo modelada como uma combinação de suas próprias defasagens (também chamadas de atrasos ou *lags*) e, opcionalmente, de variáveis exógenas. Por outro lado, a modelagem multivariada envolve a construção de um modelo preditivo unificado que considera todas as séries temporais simultaneamente [19]. Essa abordagem busca capturar os padrões principais que regem as séries, reduzindo o impacto de possíveis ruídos individuais, podendo gerar generalizações mais robustas entre as séries, embora, em alguns casos, possa sacrificar algum conhecimento específico de cada uma [20].

**2) Arquitetura LSTM:** As *long short-term memory networks* (LSTMs) são uma arquitetura específica de redes neurais recorrentes projetada para modelar dependências temporais de curto e longo prazo em dados sequenciais, mitigando o problema do desaparecimento do gradiente observado em *recurrent neural networks* (RNNs) tradicionais [21]. O principal diferencial das LSTMs reside em sua célula de memória, composta por mecanismos de controle conhecidos como portas de entrada (*input gate*), esquecimento (*forget gate*) e saída (*output gate*), que regulam o fluxo de informações ao longo da sequência temporal. Essa estrutura permite que o modelo retenha ou descarte informações relevantes de forma adaptativa, tornando-o especialmente eficaz em tarefas de previsão em séries temporais complexas [22].

O treinamento de modelos LSTM é realizado por meio do algoritmo de *backpropagation through time* (BPTT), no qual os pesos são ajustados para minimizar a função de perda com base nos erros acumulados ao longo da sequência. Em séries temporais multivariadas, como na estimativa da evapotranspiração de referência (ET<sub>0</sub>), múltiplas variáveis meteorológicas são fornecidas simultaneamente como vetores de entrada em cada passo de tempo, permitindo ao modelo capturar tanto padrões individuais quanto relações temporais entre as variáveis. Apesar de sua elevada capacidade de modelagem temporal, as LSTMs apresentam maior custo computacional e menor paralelização em comparação com arquiteturas convolucionais, devido à natureza sequencial de suas operações [21, 23].

**3) Redes Neurais Convolucionais para Séries Temporais:** As *temporal convolutional neural networks* (TCNs) são uma variação das redes neurais convolucionais adaptadas para o processamento de dados sequenciais e temporais. Diferentemente das convolutional neural networks (CNNs) tradicionais, amplamente utilizadas em processamento de imagens, as TCNs operam ao longo da dimensão temporal, permitindo a identificação de padrões temporais complexos em séries multivariadas e a modelagem de dependências de curto e longo

prazo [23]. Sua arquitetura é composta por camadas convolucionais unidimensionais (1D), incluindo convoluções causais, que garantem que a saída em um instante dependa apenas de entradas passadas e presentes, e convoluções dilatadas, que possibilitam a captura de dependências de longo prazo com menor profundidade de rede. Além disso, o uso de conexões residuais, inspiradas nas redes ResNet, contribui para maior estabilidade durante o processo de aprendizado [23, 24, 25].

O treinamento de uma TCN consiste no ajuste dos filtros convolucionais visando à minimização de uma função de perda. Diferentemente das arquiteturas recorrentes, a TCN não requer o uso do método de *backpropagation*, uma vez que seu caminho de retropropagação é independente da direção temporal da sequência, superando uma limitação comum das RNNs [23]. Em séries temporais multivariadas, como na previsão da evapotranspiração de referência (ETo), cada variável é tratada como um canal de entrada distinto, permitindo que o modelo aprenda tanto padrões individuais quanto interações entre as variáveis [26]. Após o treinamento, a TCN utiliza dados históricos para realizar previsões de curto, médio e longo prazo de forma eficiente, beneficiando-se da paralelização inherente à estrutura convolucional, o que resulta em tempos de inferência inferiores aos observados em modelos recorrentes, como a LSTM e *gated recurrent unit* (GRU) [23].

4) *Modelos Transformer*: O modelo Transformer é uma arquitetura de redes neurais introduzida para o processamento de dados sequenciais, baseada exclusivamente em mecanismos de atenção, dispensando o uso de recorrência e convoluções [27]. Seu principal componente é o mecanismo de *self-attention*, que permite ao modelo ponderar dinamicamente a relevância de diferentes posições da sequência ao construir representações internas, capturando dependências de curto e longo prazo de forma eficiente.

Para preservar a informação de ordem temporal, o Transformer incorpora *positional encoding* às representações de entrada, uma vez que a arquitetura não impõe, por si só, uma estrutura sequencial explícita. A arquitetura é composta por blocos empilhados de camadas de atenção multi-cabeça (*multi-head attention*) e redes *feedforward* totalmente conectadas, intercaladas com normalização e conexões residuais, o que contribui para a estabilidade e profundidade do modelo [27].

O treinamento de modelos Transformer é realizado por meio da retropropagação convencional, com a minimização de uma função de perda, sem a necessidade de *backpropagation*. Em séries temporais multivariadas, cada variável pode ser tratada como uma dimensão adicional do vetor de entrada em cada instante, permitindo ao modelo aprender padrões temporais complexos e relações globais entre as variáveis ao longo da sequência. A ausência de dependências sequenciais explícitas possibilita alto grau de paralelização durante o treinamento e a inferência, resultando em maior eficiência computacional em comparação com modelos recorrentes, especialmente em cenários de séries longas [27, 23].

5) *Aprendizado Federado (Federated Learning)*: O aprendizado federado (*Federated Learning – FL*) é um paradigma de aprendizado de máquina distribuído no qual múltiplos clientes

treinam modelos localmente sobre seus próprios conjuntos de dados, compartilhando apenas atualizações de parâmetros com um servidor central, sem a necessidade de centralização dos dados brutos [28]. Essa abordagem viabiliza o treinamento colaborativo em cenários com dados sensíveis ou distribuídos, preservando a privacidade das fontes e reduzindo custos de comunicação. No contexto de séries temporais meteorológicas, o FL é particularmente interessante devido à heterogeneidade espacial, temporal e estatística dos dados coletados por diferentes estações, permitindo que cada cliente contribua para um modelo global sem expor diretamente seus registros locais.

Em frameworks síncronos de aprendizado federado, o processo de agregação é tipicamente realizado por meio do algoritmo *Federated Averaging* (FedAvg), que constitui o mecanismo central de combinação das atualizações locais [28]. Nesse algoritmo, o servidor central agrupa os parâmetros dos modelos treinados localmente por meio de uma média ponderada, na qual o peso atribuído a cada cliente é proporcional ao número de amostras disponíveis em seu conjunto de dados local. O modelo global resultante é então redistribuído aos clientes para um novo ciclo de treinamento, permitindo a convergência iterativa do sistema federado. O FedAvg combina simplicidade computacional com eficácia empírica, sendo comumente adotado como referência em estudos de aprendizado federado.

### III. TRABALHOS RELACIONADOS

Em contextos com dados limitados, modelos ANFIS, MARS, *Random Forest* e XGBoost, estimando a *ETo* usando dados diários e horários, mostraram desempenho superior ao das equações convencionais de Penman-Monteith e Hargreaves-Samani em condições de dados incompletos e em regiões semiáridas [10, 29].

Redes neurais convolucionais temporais para prever a *ETo* em Sete Lagoas, Minas Gerais, foram exploradas usando dados históricos de 1993 a 2015 e os modelos *ensemble* de CNN superaram modelos individuais e um modelo Naïve, especialmente para horizontes curtos [8]. Em outra direção, modelos de autorregressão vetorial foram aplicados para previsão de curto prazo de parâmetros climáticos, mostrando 97% de precisão em variáveis como temperatura mínima e umidade relativa máxima [30].

O modelo XGBoost também foi utilizado para a predição de *ETo* em 3 localidades da Região das Matas de Minas, em Minas Gerais, sendo avaliado em dois cenários: com todas as variáveis meteorológicas; e somente com dados de temperatura. O autor viu potencial no modelo, mas notou a ocorrência de superestimativas nos valores de *ETo* nos dois cenários [31].

Estudos comparativos entre abordagens também são comuns. Modelos baseados em árvores de decisão (*Decision Tree*, RF, e XGBoost) foram comparados com os resultados obtidos com modelos CNN, avaliando previsões de *ETo* em diferentes regiões do Brasil [13]. Em outro trabalho, seis modelos híbridos de aprendizado de máquina foram avaliados para estimativa de *ETo* na China, e o modelo DNN-RF teve o

melhor desempenho nas métricas CC, MAE, RMSE, RAE e RRSE [32].

Estudos asiáticos têm investigado diferentes variáveis para melhorar as previsões de *ETo*. Na China, o GBM foi identificado como o modelo mais eficaz ao incorporar variáveis meteorológicas para estimativas de *ETo* com base na equação de Penman-Monteith [33]. Em outro estudo asiático, o modelo VAR foi utilizado para investigar a relação causal entre variáveis meteorológicas e *ETo* em Penang, Malásia, mostrando a importância do período de dados históricos para a precisão [34].

No último ano, os estudos continuaram: buscando determinar as contribuições das variáveis meteorológicas e das posições geográficas de coleta, em diferentes épocas do ano ([35]); avaliando diferentes combinações de variáveis de entrada ([36, 37]); investigando a limitação de informação, a partir da simulação da perda de dados em sistemas de coleta de *Internet of Things* ([38]); experimentando modelos de aprendizado de máquina e aprendizado profundo, tradicionais ou híbridos, comparando com métodos empíricos ([39, 40, 41, 42, 43]); avaliando o agrupamento de zonas climáticas heterogêneas em zonas homogêneas via técnicas de *clustering* ([44]); e, finalmente, propondo uma abordagem de treinamento distribuído, com o objetivo de obter estimativas de *ETo* mais generalizadas através de dados de diferentes regiões ([45]).

#### IV. MATERIAIS E MÉTODOS

A metodologia proposta foi dividida em três etapas principais: (i) preparação dos dados e análise exploratória, (ii) desenvolvimento e avaliação dos modelos de aprendizado profundo, e (iii) concepção de um ambiente experimental distribuído com suporte a aprendizado federado.

Na primeira etapa, foram utilizados conjuntos de dados meteorológicos provenientes do repositório de dados do *Brazilian Daily Weather Gridded Data* (BDWGD), resultante do trabalho de [46], representando diferentes tipos climáticos do Brasil (equatorial, semiárido, tropical, tropical de altitude, tropical litorâneo e subtropical). As variáveis de entrada incluirão radiação solar (*Rs*), velocidade do vento (*u<sub>2</sub>*), temperatura máxima (*Tmax*), temperatura mínima (*Tmin*), umidade relativa do ar (*RH*) e precipitação (*pr*), enquanto a variável-alvo será a *ETo*. Os dados foram organizados em séries temporais multivariadas, com janelas deslizantes (*lags*) de entrada e normalização por meio de escalonamento min–max.

Na segunda etapa, foram implementadas e comparadas três arquiteturas de redes neurais profundas:

- LSTM: redes recorrentes capazes de capturar dependências temporais de longo prazo;
- TCN: redes convolucionais causais com dilatação temporal, que permitem maior paralelismo e estabilidade de treinamento;
- Transformer: modelo baseado em mecanismos de autoatenção, que permite a modelagem de dependências dinâmicas entre variáveis e instantes temporais.

Os hiperparâmetros das arquiteturas (Tabela I) foram definidos de forma consistente entre os modelos, priorizando

comparabilidade experimental. Todas as redes utilizaram janelas temporais de quatro observações, função de perda MSE e otimização via Adam, com parada antecipada baseada no RMSE de validação.

**Tabela I**  
HIPERPARÂMETROS DAS ARQUITETURAS DE DEEP LEARNING UTILIZADAS

Hiperparâmetro	LSTM	TCN	Transformer
Tipo de arquitetura	LSTM unidirecional	TCN causal	Transformer Encoder
Número de camadas	2	2 blocos (64, 64)	2 encoder layers
Unidades / filtros	64		64 (d_model)
Kernel size	–	2 <sup>i</sup>	–
Dilatação	–	–	–
Cabeças de atenção	–	–	4
Dimensão feedforward	–	–	128
Função de ativação	tanh / ReLU	ReLU	ReLU
Dropout	0.2	0.2	0.1
Bidirecional	Não	–	–
Janela temporal (seq_len)	4	4	4
Camada de saída	FC (64→32→1)	FC (64→32→1)	FC (64→32→1)
Função de perda	MSE	MSE	MSE
Otimizador	Adam	Adam	Adam
Taxa de aprendizado	$1 \times 10^{-3}$	$1 \times 10^{-3}$	$1 \times 10^{-3}$
Weight decay	$1 \times 10^{-6}$	$1 \times 10^{-6}$	$1 \times 10^{-6}$
Batch size	64	64	64
Máx. de épocas	50	50	50
Early stopping (RMSE)	Sim (patience=8)	Sim	Sim

O treinamento foi conduzido em ambiente PyTorch, com scripts Python, com validação cruzada temporal e métricas de avaliação como o Erro Quadrático Médio (RMSE), o Erro Absoluto Médio (MAE) e o Coeficiente de Determinação ( $R^2$ ).

Na terceira etapa, o aprendizado federado foi explorado com a simulação de um ambiente com múltiplos clientes (estações meteorológicas locais), cada um treinando um modelo localmente (modelo LSTM) e contribuindo com atualizações agregadas ao modelo global. Essa abordagem permitiu investigar o desempenho e a estabilidade de modelos treinados de forma descentralizada, mantendo os dados meteorológicos em suas origens.

Nesta fase, adotou-se um framework de Aprendizado Federado síncrono (Figura 2), baseado no algoritmo *Federated Averaging* (FedAvg), no qual múltiplos clientes treinam localmente um modelo LSTM para estimativa da evapotranspiração de referência (*ETo*), preservando a privacidade dos dados. Cada cliente representa uma localidade/clima distinto e mantém seus dados meteorológicos localmente, sem compartilhamento direto com o servidor central. Todas as configurações encontram-se apresentadas na Tabela II.

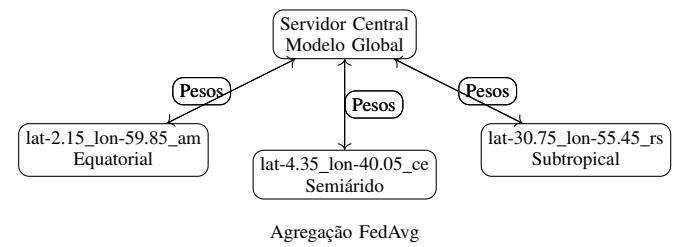


Figura 2. Esquema do framework de Aprendizado Federado adotado. Exemplo com 3 clientes (climas).

O treinamento ocorre em rodadas federadas. Em cada rodada, o servidor distribui os pesos do modelo global para

um subconjunto de clientes participantes. Cada cliente realiza treinamento local por um número fixo de épocas e retorna os pesos atualizados ao servidor. A agregação é realizada por média ponderada, considerando o número de amostras locais de cada cliente. Após a agregação, o modelo global é redistribuído e avaliado nos conjuntos de teste locais.

Tabela II  
CONFIGURAÇÃO DO FRAMEWORK DE APRENDIZADO FEDERADO ADOTADO

Componente	Descrição
Paradigma de FL	Aprendizado Federado síncrono
Algoritmo de agregação	Federated Averaging (FedAvg)
Topologia	Cliente–Servidor central
Participação por rodada	Total
Modelo local	LSTM unidirecional (2 camadas, 64 unidades)
Inicialização global	Estrutura do primeiro cliente
Treinamento local	1 época por rodada
Função de perda	Mean Squared Error (MSE)
Otimizador local	Adam ( $\eta = 10^{-3}$ )
Ponderação na agregação	Número de amostras locais
Sincronização	Síncrona por rodada
Compartilhamento de dados	Não (apenas pesos do modelo)
Escalonamento de dados	Padronização local (StandardScaler)
Janela temporal	4 observações passadas
Avaliação	RMSE, MAE e $R^2$ em teste local
Número de rodadas	10

As bases de dados e códigos implementados para os experimentos estão disponíveis em <https://github.com/ppgcc-decom-ufop/pcc177.git>.

## V. RESULTADOS E DISCUSSÃO

### A. Avaliação dos modelos de aprendizado profundo

Considerando a hipótese de que modelos baseados em aprendizado profundo são capazes de capturar padrões temporais complexos associados à variabilidade climática da ET<sub>0</sub>, o desempenho dos modelos foi avaliado no conjunto de teste, utilizando-se como critério principal a raiz do erro quadrático médio (RMSE). Essa métrica foi adotada por expressar diretamente o erro médio da estimativa na mesma unidade da variável de interesse. Como critério complementar, empregou-se o coeficiente de determinação ( $R^2$ ), utilizado apenas em situações de empate técnico, caracterizadas por diferenças marginais de RMSE entre modelos concorrentes. Nas tabelas a seguir (Tabela III, Tabela IV, Tabela V, Tabela VII, Tabela VI e Tabela VIII), é possível ver o desempenho dos modelos em cada clima.

Tabela III  
DESEMPENHOS DOS MODELOS NO CLIMA EQUATORIAL (AM)

Modelo	RMSE	MAE	$R^2$
TCN	0.8263	0.6975	0.0771
<b>LSTM</b>	<b>0.7505</b>	<b>0.6088</b>	<b>0.2385</b>
Transformer	0.7628	0.6332	0.2136

Os resultados mostram que arquiteturas baseadas em redes neurais recorrentes e mecanismos de atenção são capazes de modelar adequadamente a dinâmica temporal da ET<sub>0</sub> em diferentes climas brasileiros. O modelo LSTM apresentou o

Tabela IV  
DESEMPENHOS DOS MODELOS NO CLIMA SEMIÁRIDO (CE)

Modelo	RMSE	MAE	$R^2$
TCN	0.6789	0.5324	0.6953
<b>LSTM</b>	<b>0.6477</b>	<b>0.4978</b>	<b>0.7227</b>
Transformer	0.6651	0.5055	0.7076

Tabela V  
DESEMPENHOS DOS MODELOS NO CLIMA TROPICAL LITORÂNEO (PE)

Modelo	RMSE	MAE	$R^2$
TCN	0.6408	0.5012	0.6295
<b>LSTM</b>	<b>0.6335</b>	<b>0.4962</b>	<b>0.6379</b>
Transformer	0.6522	0.4945	0.6163

melhor desempenho em quatro dos seis climas analisados (Equatorial, Semiárido, Tropical Litorâneo e Tropical de Altitude), atendendo de forma consistente ao objetivo de fornecer estimativas precisas e estáveis. Nos climas Tropical Típico e Subtropical, o modelo Transformer apresentou desempenho levemente superior em termos de RMSE e  $R^2$ .

Portanto, embora modelos mais complexos possam capturar dependências de longo alcance em determinados regimes climáticos, os ganhos obtidos não são suficientes para justificar a adoção de arquiteturas distintas, considerando os objetivos de generalização e simplicidade metodológica deste trabalho.

### B. Avaliação do ambiente de aprendizado federado

Para a etapa de implementação do cenário utilizando aprendizado federado, o modelo LSTM foi adotado em função do seu desempenho superior ou estatisticamente equivalente ao dos demais modelos em todos os climas, pela consistência dos resultados ao longo dos diferentes regimes climáticos e pela menor complexidade computacional em comparação ao modelo Transformer.

O ambiente experimental baseado em simulação permitiu avaliar o aprendizado federado com experimentos controlados e reproduíveis, ao mesmo tempo em que isolou o comportamento algorítmico de fatores relacionados à infraestrutura. Essa abordagem costuma ser adotada na literatura de aprendizado federado para o estudo da convergência, da heterogeneidade dos dados e do desempenho dos modelos, constituindo uma base confiável para extensões futuras em ambientes distribuídos reais.

O desempenho do modelo LSTM treinado por meio de Aprendizado Federado (FL) foi avaliado considerando seis clientes geograficamente distribuídos, representando diferentes climas brasileiros. Cada cliente treinou localmente o modelo utilizando apenas seus próprios dados meteorológicos, enquanto o servidor central agregou os parâmetros via algoritmo FedAvg ao longo de 10 rodadas de comunicação.

As médias apresentadas na Tabela IX, cujos desvios-padrão foram todos abaixo de 0,048, indicam que o modelo LSTM federado apresentou bom desempenho preditivo em climas tropicais, tropicais de altitude e subtropicais. Em particular,

**Tabela VI**  
DESEMPENHO DOS MODELOS NO CLIMA TROPICAL DE ALTITUDE (MG)

Modelo	RMSE	MAE	R <sup>2</sup>
TCN	0.7608	0.5614	0.5971
<b>LSTM</b>	<b>0.7403</b>	<b>0.5345</b>	<b>0.6185</b>
Transformer	0.7502	0.5266	0.6083

**Tabela VII**  
DESEMPENHO DOS MODELOS NO CLIMA TROPICAL (MT)

Modelo	RMSE	MAE	R <sup>2</sup>
TCN	0.7447	0.5876	0.3347
LSTM	0.7191	0.5581	0.3796
<b>Transformer</b>	<b>0.7183</b>	<b>0.5512</b>	<b>0.3811</b>

os clientes localizados em Pernambuco, Minas Gerais e Mato Grosso apresentaram valores de RMSE inferiores a 0,8 e coeficientes de determinação superiores a 0,3, chegando a aproximadamente 0,6 no caso de Minas Gerais, o que evidencia capacidade satisfatória de captura da variabilidade temporal da evapotranspiração de referência.

Por outro lado, o desempenho do modelo foi significativamente inferior nos climas equatorial e semiárido, representados pelos clientes do Amazonas e do Ceará, respectivamente. Nesses casos, os valores de R<sup>2</sup> foram próximos de zero ou negativos ao longo de todas as rodadas, indicando que o modelo global federado não superou um preditor ingênuo baseado na média histórica da série.

Esses resultados sugerem que, embora o Aprendizado Federado permita a construção de um modelo global sem compartilhamento de dados brutos, sua eficácia depende fortemente da similaridade dos padrões climáticos entre os clientes participantes.

## VI. CONCLUSÃO

Este trabalho investigou a aplicação de modelos de aprendizado profundo em um contexto de aprendizado federado para a estimativa multivariada da evapotranspiração de referência em diferentes climas brasileiros. Os resultados demonstraram que o modelo LSTM apresentou desempenho consistente e superior ou equivalente às arquiteturas TCN e Transformer na maioria dos cenários analisados, justificando sua adoção como modelo local no ambiente federado.

A abordagem federada mostrou-se viável, permitindo o treinamento colaborativo sem compartilhamento de dados brutos, embora tenha apresentado limitações em climas extremos, reflexo da heterogeneidade climática e estatística entre os clientes. Ainda assim, o aprendizado federado desponta como uma alternativa promissora para aplicações distribuídas em monitoramento ambiental e apoio ao manejo da irrigação.

Como perspectivas de continuidade, propõe-se a investigação de estratégias adaptativas, incluindo modelos personalizados por cliente, agrupamento de clientes com base em similaridade climática e técnicas de *fine-tuning* local do modelo global. Além disso, a implementação

**Tabela VIII**  
DESEMPENHO DOS MODELOS NO CLIMA SUBTROPICAL (RS)

Modelo	RMSE	MAE	R <sup>2</sup>
TCN	0.9707	0.7305	0.7086
LSTM	0.9564	0.7117	0.7172
<b>Transformer</b>	<b>0.9538</b>	<b>0.7069</b>	<b>0.7187</b>

**Tabela IX**  
SÍNTESE DO DESEMPENHO MÉDIO DO MODELO LSTM EM APRENDIZADO FEDERADO POR CLIMA BRASILEIRO

Cliente	Clima	RMSE	MAE	R <sup>2</sup>	Avaliação
AM	EQ	0.9717	0.7628	< 0	Fraco
CE	SA	1.2162	1.0699	≈ 0	Fraco
PE	TL	0.7412	0.6181	0.5040	Bom
MT	TT	0.7420	0.5572	0.3394	Moderado
MG	TA	0.7560	0.5626	0.6021	Muito bom
RS	ST	1.3384	1.1272	0.4456	Bom

**Nota:** Os valores apresentados correspondem a intervalos aproximados obtidos a partir das rodadas finais (6 a 10) do treinamento federado. A média de RMSE é expressa nas mesmas unidades da evapotranspiração de referência (mm dia<sup>-1</sup>).

do *framework* em um ambiente federado real, com o uso de plataformas como o *Flower*, permitirá avaliar fatores práticos como latência de comunicação, falhas de conectividade, escalabilidade e participação parcial de clientes. Esses experimentos contribuirão para aproximar o modelo de cenários reais envolvendo estações meteorológicas distribuídas, dispositivos de borda e infraestruturas em nuvem.

## REFERÊNCIAS

- [1] Agência Nacional de Águas e Saneamento Básico, “Atlas irrigação: uso da água na agricultura irrigada,” Brasília, 2021.
- [2] Food and Agriculture Organization of the United Nations, *Water for Sustainable Food and Agriculture Organization of the United Nations. A report produced for the G20 Presidency of Germany. Technical report.* Roma: Food and Agriculture Organization of the United States (FAO), 2017.
- [3] Serviço Nacional de Aprendizagem Rural, “Irrigação: gestão e manejo. / serviço nacional de aprendizagem rural. coleção senar, 250,” Brasília, p. 84, 2019.
- [4] G. T. Novais, *Climas do Brasil: classificação climática e aplicações*, 1st ed. Porto Alegre, RS: Editora Totalbooks Eireli, 2023.
- [5] R. Allen, L. Pereira, D. Raes, and M. Smith, “Evapotranspiración del cultivo. guías para la determinación de los requerimientos de agua de los cultivos,” *Estudio FAO Riego Y Drenaje No 56*, 01 2006.
- [6] P. R. A. Krishna, “Evapotranspiration and agriculture-a review,” *Agricultural Reviews*, vol. 40, pp. 1–11, 2019.
- [7] P. Lucas, R. Maia, M. Vicente, and C. Leite, “Using artificial neural network to estimate reference evapotranspiration,” *Global Science and Technology*, vol. 11, pp. 229–240, 12 2018.

- [8] P. d. O. e. Lucas, “Previsão de séries temporais de evapotranspiração de referência com redes neurais convolucionais.” Master’s thesis, Universidade Federal de Minas Gerais, Escola de Engenharia, 2019.
- [9] K. C. d. Meneses, L. E. D. O. Aparecido, K. C. d. Meneses, and M. F. d. Farias, “Estimating potential evapotranspiration in maranhão state using artificial neural networks,” *Revista Brasileira de Meteorologia*, vol. 35, no. 4, p. 675–682, Oct 2020.
- [10] L. B. Ferreira and F. F. da CUNHA, “New approach to estimate daily reference evapotranspiration based on hourly temperature and relative humidity using machine learning and deep learning,” *Agricultural Water Management*, vol. 234, p. 106113, 2020.
- [11] L. B. Ferreira, F. F. da Cunha, and E. I. F. Filho, “Exploring machine learning and multi-task learning to estimate meteorological data and reference evapotranspiration across brazil,” *Agricultural Water Management*, vol. 259, p. 107281, 2022.
- [12] P. Guo, J. Cao, and J. Lin, “Establishment of a reference evapotranspiration forecasting model based on machine learning,” *Agronomy*, vol. 14, no. 5, 2024.
- [13] R. da Silva Basílio, “Previsão de séries temporais de evapotranspiração de referência e desenvolvimento de estação meteorológica,” Ouro Preto, 2023.
- [14] A. S. Fleischmann, L. Laipelt, F. Papa, R. C. D. d. Paiva, B. C. de Andrade, W. Collischonn, M. S. Biudes, R. Kayser, C. Prigent, E. Cosio, N. G. Machado, and A. Ruhoff, “Patterns and drivers of evapotranspiration in south american wetlands,” *Nature Communications*, vol. 14, no. 1, p. 6656, Oct 2023.
- [15] M. E. Jensen and R. G. Allen, *Evaporation, Evapotranspiration and Irrigation Water Requirements - ASCE Manuals and Reports on Engeneering Practice No. 70*, 2nd ed. Reston, Virginia: American Society of Civil Engineers, 2016.
- [16] R. Gouveia, “Climas do brasil,” Toda Matéria, s.d. [Online]. Available: <https://www.todamateria.com.br/climas-do-brasil/>
- [17] IBGE, *Atlas geográfico escolar*, 9th ed. Rio de Janeiro: IBGE, Centro de Documentação e Disseminação de Informações, 1993.
- [18] M. Oliveira, “Climas do brasil,” TudoGeo, 2020. [Online]. Available: <https://www.tudogeo.com.br/2020/05/07/climas-do-brasil/>
- [19] J. A. Rodrigo and J. E. Ortiz, “Global Forecasting Models: Modeling Multiples Time Series with Machine Learning — cienciadedatos.net,” 2022.
- [20] ——, “Global Forecasting Models: Comparative Analysis of Single and Multi-Series Forecasting Modeling — cienciadedatos.net,” 2023.
- [21] S. Hochreiter and J. Schmidhuber, “Long short-term memory,” *Neural Computation*, vol. 9, no. 8, pp. 1735–1780, 1997. [Online]. Available: <https://direct.mit.edu/neco/article/9/8/1735/6109/Long-Short-Term-Memory>
- [22] F. A. Gers, J. Schmidhuber, and F. Cummins, “Learning to forget: Continual prediction with LSTM,” *Neural Computation*, vol. 12, no. 10, pp. 2451–2471, 2000. [Online]. Available: <https://direct.mit.edu/neco/article/12/10/2451/6456/Learning-to-Forget-Continual-Prediction>
- [23] S. Bai, J. Z. Kolter, and V. Koltun, “An empirical evaluation of generic convolutional and recurrent networks for sequence modeling,” 2018.
- [24] B. Zeng, “Towards understanding residual neural networks,” Master’s thesis, Massachusetts Institute of Technology, 2019.
- [25] Y. Liu, H. Dong, X. Wang, and S. Han, “Time series prediction based on temporal convolutional network,” in *2019 IEEE/ACIS 18th International Conference on Computer and Information Science (ICIS)*, 2019, pp. 300–305.
- [26] R. Gonçalves, “Understanding random forest, from theory to practice,” Ph.D. dissertation, Department of Electrical Engineering and Computer Science, Faculty of Engineering, University of Porto, Porto, Portugal, 2021.
- [27] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser, and I. Polosukhin, “Attention is all you need,” in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 30, 2017. [Online]. Available: <https://papers.nips.cc/paper/7181-attention-is-all-you-need>
- [28] B. McMahan, E. Moore, D. Ramage, S. Hampson, and B. A. y. Arcas, “Communication-efficient learning of deep networks from decentralized data,” in *Proceedings of the 20th International Conference on Artificial Intelligence and Statistics (AISTATS)*, 2017, pp. 1273–1282. [Online]. Available: <https://proceedings.mlr.press/v54/mcmahan17a.html>
- [29] L. Ferreira, F. Cunha, G. da Silva, F. Campos, S. H. Dias, and J. Santos, “Generalizability of machine learning models and empirical equations for the estimation of reference evapotranspiration from temperature in a semi-arid region,” *Anais da Academia Brasileira de Ciências*, vol. 23, p. e20200304, 03 2021.
- [30] W. Abdallah, N. Abdallah, J.-M. Marion, M. Oueidat, and P. Chauvet, “A vector autoregressive methodology for short-term weather forecasting: tests for lebanon,” p. 1555, 2020.
- [31] D. R. Q. Rosa, “Aplicação de machine learning para predição da evapotranspiração de referência (eto),” São Paulo, 2022.
- [32] A. Elbeltagi, A. Srivastava, P. Li, J. Jiang, D. Jinsong, J. Rajput, L. Khadke, and A. Awad, “Forecasting actual evapotranspiration without climate data based on stacked integration of dnn and meta-heuristic models across china from 1958 to 2021,” *Journal of Environmental Management*, vol. 345, p. 118697, 2023.
- [33] V. Gaddikeri, M. S. Jatav, Siddharam, K. R. Asha, L. Aiswarya, Preeti, and B. Nageswar, “Predictive modeling and comparative analysis of reference evapotranspiration with machine learning algorithms,” *International Journal of Environment and Climate Change*, vol. 13,

- no. 11, p. 1623–1634, Oct. 2023.
- [34] P. S. Hou, L. M. Fadzil, S. Manickam, and M. A. Al-Shareeda, “Vector autoregression model-based forecasting of reference evapotranspiration in malaysian,” *Sustainability*, vol. 15, no. 4, 2023.
- [35] G. L. Melo, M. T. Petry, J. D. Martins, and B. d. Villa, “Análise de componentes principais e contribuições das variáveis e estações meteorológicas na determinação da evapotranspiração de referência no estado do rio grande do sul,” *Revista Brasileira de Climatologia*, vol. 37, no. 21, p. 474–492, out. 2025. [Online]. Available: <https://ojs.ufgd.edu.br/rbclima/article/view/19451>
- [36] S. Karuppanan, S. Ramasamy, B. Lakshminarayanan, and S. Nariangadu Anuthaman, “An effective machine learning model for the estimation of reference evapotranspiration under data-limited conditions,” *Research in Agricultural Engineering*, vol. 71, no. 1, pp. 22–37, 2025. [Online]. Available: <https://rae.agriculturejournals.cz/artkey/rae-202501-0003.php>
- [37] M. Mustapha, M. Zineddine, M. Gmira, M. El Mouhtadi, and A. E. H. Alaoui, “Machine learning approaches for predicting reference evapotranspiration: A comparative study using ground and gridded climate data in fes region,” *World Water Policy*, vol. 11, no. 2, pp. 652–669, 2025. [Online]. Available: <https://onlinelibrary.wiley.com/doi/abs/10.1002/wwp2.12255>
- [38] Y. Boukhali, M. N. Kabbaj, and M. Benbrahim, “Evapotranspiration estimation using deep learning models for robust sensor performance,” *Franklin Open*, vol. 12, p. 100335, 2025. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S2773186325001239>
- [39] T. Y. Fong, Y. F. Huang, R. J. Chin, and C. H. Koo, “Enhanced estimation of reference evapotranspiration using hybrid deep learning models and remote sensing variables,” *Agricultural Water Management*, vol. 315, p. 109534, 2025. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0378377425002483>
- [40] G. Huang, J. Dong, L. Wu, J. Luo, R. Qiu, Y. Cui, and Y. Wang, “A new regional reference evapotranspiration model based on quantile approximation of meteorological variables,” *Agricultural Water Management*, vol. 308, p. 109299, 2025. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0378377425000137>
- [41] S. I. Jiménez-Jiménez, M. de Jesús Marcial-Pablo, I. Sánchez-Cohen, W. Ojeda-Bustamante, M. A. Inzunza-Ibarra, and J. A. Urrieta-Velazquez, “Estimating reference evapotranspiration using reanalysis data from the google earth engine: A case study from an arid hydrological region in mexico,” *Irrigation and Drainage*, vol. n/a, no. n/a, 2025. [Online]. Available: <https://onlinelibrary.wiley.com/doi/abs/10.1002/ird.3099>
- [42] E. Lujano, R. Lujano, J. C. Huamani, and A. Lujano, “Assessment of machine learning techniques to estimate reference evapotranspiration at yauri meteorological station, peru,” in *The 4th International Electronic Conference on Forests*. Basel Switzerland: MDPI, Jun. 2025, p. 20.
- [43] S. S. Sarkar, J. Bedi, and S. Jain, “A deep learning based framework for enhanced reference evapotranspiration estimation: evaluating accuracy and forecasting strategies,” *Scientific Reports*, vol. 15, no. 1, p. 15136, Apr 2025. [Online]. Available: <https://doi.org/10.1038/s41598-025-99713-2>
- [44] E. Shrestha, S. Poudyal, A. Ghimire, S. Maharjan, M. Lamichhane, and S. Mehan, “Evaluating empirical and machine learning approaches for reference evapotranspiration estimation using limited climatic variables in nepal,” *Results in Engineering*, vol. 25, p. 104254, 2025. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S2590123025003391>
- [45] M. Tausif, M. W. Iqbal, R. N. Bashir, B. AlGhofaily, A. Elyassih, and A. R. Khan, “Federated learning based reference evapotranspiration estimation for distributed crop fields,” *PLoS One*, vol. 20, no. 2, p. e0314921, Feb. 2025. [Online]. Available: <https://journals.plos.org/plosone/article?id=10.1371/journal.pone.0314921>
- [46] A. C. Xavier, B. R. Scanlon, C. W. King, and A. I. Alves, “New improved brazilian daily weather gridded data (1961–2020),” *International Journal of Climatology*, vol. 42, no. 16, pp. 8390–8404, 2022.